

PROJEK PENAMBANGAN DATA



Disusun Oleh:

L0224018	B	Fathul Fajar Nur Ikhsan
L0224019	B	Ibrahim Syauqi
L0224039	B	Zaki Elias Al Haqqani Kudus
L0224050	B	Kayla Maharani Muzaki

FAKULTAS TEKNOLOGI INFORMASI DAN SAINS DATA

PROGRAM STUDI SAINS DATA

UNIVERSITAS SEBELAS MARET

**SURAKARTA
2026**

ABSTRAK

[Tuliskan abstrak secara padat mencakup latar belakang, metode data mining yang digunakan, hasil evaluasi model, dan kesimpulan di sini...]

DAFTAR ISI

[Sisipkan struktur Daftar Isi di sini...]

DAFTAR TABEL

[Sisipkan struktur Daftar Tabel di sini...]

DAFTAR GAMBAR

[Sisipkan struktur Daftar Gambar di sini...]

BAB I

PENDAHULUAN

1.1 Latar Belakang

Gempa bumi adalah bencana alam yang dapat merenggut nyawa manusia dan mengakibatkan banyak kerugian pada masyarakat. Berdasarkan penelitian yang tercatat, Indonesia mengalami gempa bumi rata-rata 5.000 hingga 6.000 kejadian setiap tahunnya[1]. Tingginya frekuensi kejadian tersebut menunjukkan bahwa Indonesia merupakan salah satu wilayah dengan aktivitas seismik yang sangat tinggi. Hal ini juga dipengaruhi karena wilayahnya terletak di titik pertemuan tiga lempeng tektonik aktif utama dunia, lempeng Eurasia, lempeng Pasifik, lempeng indo-australia.

Oleh karena itu, penelitian yang berkaitan dengan gempa bumi telah banyak dilakukan, tetapi sayangnya sampai saat ini masih menghadapi tantangan, salah satunya disebabkan karena kompleksitas karakteristik data gempa bumi menyebabkan proses analisis dan prediksi aktivitas seismik menjadi tantangan yang cukup besar. Berbagai pendekatan berbasis data mining dan deep learning telah dikembangkan untuk membantu menemukan pola tersembunyi pada data kegempaan, seperti clustering dan neural network. Pemilihan metode yang tepat menjadi faktor penting dalam menghasilkan model analisis dan prediksi yang optimal [2] .

Salah satu pendekatan yang dapat digunakan untuk memahami pola aktivitas gempa bumi adalah teknik clustering. Apabila seluruh data historis diperlakukan sebagai satu kesatuan, luasnya cakupan geografis seringkali menimbulkan disparitas parameter yang berujung pada penurunan akurasi analisis [3]. Oleh karena itu, metode clustering diperlukan untuk mengelompokkan data kejadian gempa berdasarkan kemiripan karakteristik spasial. Pendekatan ini terbukti mampu membagi wilayah menjadi kluster atau zona seismik yang lebih homogen, sehingga model dapat memahami pola spesifik di tiap wilayah, mengurangi noise, dan menstrukturkan analisis mitigasi bencana dengan lebih presisi.

Selain itu, pemodelan data dalam bentuk deret waktu (time-series) juga menjadi bagian penting dalam analisis aktivitas gempa bumi. Pendekatan time-series memungkinkan pola temporal seperti tren, fluktuasi, maupun kemungkinan pola musiman pada aktivitas seismik untuk dianalisis secara lebih sistematis. Dengan

memodelkan frekuensi kejadian gempa pada interval waktu tertentu, seperti harian, mingguan, atau bulanan, penelitian dapat memperoleh gambaran dinamika aktivitas gempa pada masing-masing zona seismik secara lebih jelas [3].

1.2 Rumusan Masalah

- a. Bagaimana mengimplementasikan algoritma *Clustering* seperti K-Means dan DBSCAN untuk mengelompokkan data kejadian gempa bumi mentah menjadi klaster-klaster zona seismik yang homogen berdasarkan karakteristik geologis dan spasialnya?
- b. Bagaimana proses transformasi data kejadian pada masing-masing klaster zona seismik tersebut menjadi deret waktu (*time-series*) berinterval tetap untuk memodelkan frekuensi kegempaan?
- c. Bagaimana penerapan dan keandalan arsitektur *Deep Learning LSTM (Long Short-Term Memory)* dalam meramalkan tren frekuensi kejadian gempa bumi pada setiap klaster, serta seberapa rendah tingkat kesalahan prediksinya (*forecasting error*) berdasarkan metrik evaluasi yang digunakan?

1.3 Batasan

Agar proyek ini tetap fokus dan terarah, batasan masalah ditetapkan sebagai berikut:

- a. Dataset & Wilayah : Menggunakan data historis kejadian gempa bumi di wilayah teritorial Indonesia dengan batas wilayah (*spatial filtering*) tidak menggunakan batas koordinat imajiner ataupun batas wilayah regional, melainkan disaring menggunakan data batasan resmi berdasarkan Zona Ekonomi Eksklusif (ZEE) Indonesia dari *MarineRegions*. Hal ini memastikan seluruh data gempa yang dianalisis merupakan data yang berada di wilayah Indonesia baik di laut maupun daratan. Data bersumber dari katalog resmi *United States Geological Survey (USGS)* pada rentang waktu tahun 2000 hingga tahun 2026.
- b. Pemodelan : Pemodelan dibatasi hanya pada pendekatan dua tahap, yaitu tahap pertama menggunakan algoritma *Clustering* seperti K-Means dan DBSCAN untuk membentuk klaster zona seismik alami berdasarkan fitur spasial geologis dan aktivitas gempa, diikuti tahap kedua menggunakan regresi untuk meramalkan tren frekuensi kejadian gempa bumi bulanan pada masing-masing klaster yang terbentuk.

- c. Evaluasi : Kinerja model dievaluasi secara kuantitatif menggunakan metrik pengukuran error regresi/prediksi, yaitu *Root Mean Square Error* (RMSE) dan *Mean Absolute Error* (MAE). Penelitian ini tidak memprediksi letak koordinat spasial terjadinya gempa.

1.4 Tujuan

Tujuan yang ingin dicapai adalah:

- a. Menerapkan teknik agregasi dan resampling untuk mengubah data geospasial bencana menjadi format deret waktu yang siap diproses.
- b. Mengimplementasikan dan menganalisis pemodelan hibrida dua tahap (*two-stage hybrid modeling*) yang menggabungkan algoritma *Clustering* seperti K-Means dan DBSCAN untuk pemetaan zona seismik alami dengan regresi untuk prediksi frekuensi kejadian gempa bumi pada masing-masing zona di Indonesia.
- c. Mengevaluasi efektivitas dan tingkat akurasi dari pendekatan dua tahap dalam prediksi tren frekuensi kejadian gempa bumi berdasarkan karakteristik zona seismik di Indonesia.

1.5 Manfaat

Project ini diharapkan dapat memberikan manfaat sebagai berikut:

- a. **Manfaat Teoritis:** Memperkaya kajian literatur komparatif mengenai efektivitas algoritma statistik parametrik berhadapan dengan deep learning dalam menyelesaikan masalah regresi deret waktu yang memiliki tingkat keacakan (noise) tinggi seperti data alam.
- b. **Manfaat Praktis:** Menghasilkan model proyeksi tren yang dapat memberikan wawasan atau *early warning system* berbasis agregat bagi instansi terkait. Informasi tren fluktuasi ini dapat membantu penyusunan kesiapsiagaan sumber daya jika sistem memprediksi adanya lonjakan aktivitas gempa di masa mendatang

BAB II

LANDASAN PUSTAKA

2.1 Algoritma Data Mining

Data Mining atau penambangan data adalah proses yang digunakan untuk mengekstrak informasi dan pola yang berguna dari kumpulan data-data besar. Data Mining didefinisikan sebagai teknik yang digunakan untuk menemukan informasi yang tersembunyi di dalam basis data. Proses ini merupakan bagian dari bidang yang lebih luas yaitu *Knowledge Discovery in Databases* (KDD), bidang ini mencakupi langkah-langkah seperti pembersihan data, integrasi data, pemilihan data, transformasi data, penambangan data, evaluasi pola dan presentasi pengetahuan. [5]

Dalam project ini kami menggunakan pemodelan hibrida dua tahap (*two-stage hybrid modeling*) yang menggabungkan algoritma *Clustering* seperti K-Means, Alggomerative Hierarchical dan DBSCAN untuk pemetaan zona seismik alami dengan arsitektur *Deep Learning* LSTM (*Long Short Term Memory*) untuk prediksi frekuensi kejadian gempa bumi pada masing-masing zona di Indonesia.

2.1.1 Algoritma Clustering

Clustering adalah proses pengelompokan data atau objek ke dalam kelompok-kelompok yang serupa berdasarkan kesamaan karakteristik tertentu. Karakteristik setiap *cluster* adalah kemiripan data yang tinggi di dalam satu *cluster*-nya dan ketidakmiripan data yang tinggi pada *cluster* lainnya. Tujuan dari *clustering* adalah untuk mengelompokkan data yang mirip ke dalam kelompok tertentu tanpa adanya label kelas sebelumnya. Metode pembelajaran yang digunakan *clustering* adalah pembelajaran yang tidak terawasi (*Unsupervised Learning*), artinya tidak ada label kelas di dalam data. [6]

Clustering memiliki beberapa jenis salah satunya adalah *Partitional Clustering*. Dalam *Partitional Clustering* data dikelompokkan pada sejumlah *cluster*, dimana setiap titik data hanya bisa menjadi bagian dari satu *cluster*. Sebelumnya jumlah *cluster* sudah ditentukan terlebih dahulu. Beberapa algoritma *Partitional Clustering* diantaranya *K-Means*, *K-Medoids* dan *Fuzzy C-Means*. [6]

2.1.1.1 Algoritma K-Means

K-Means merupakan algoritma clustering yang paling populer dan sederhana. [6] K-Means terkenal karena kemudahan dan kemampuannya untuk mengklaster data yang besar dan data outlier dengan sangat cepat. K-Means adalah metode clustering berbasis jarak yang membagi data ke dalam sejumlah cluster dan algoritma ini hanya bekerja pada atribut numerik. Dalam K-Means, setiap data harus termasuk ke dalam cluster tertentu dan data bisa masuk ke dalam cluster tertentu pada salah satu tahapan proses, pada tahapan berikutnya akan berpindah ke cluster lainnya. [7] Langkah-langkah K-Means adalah sebagai berikut :

- a. Pilih jumlah *cluster*.
- b. Inisialisasi awal dan pusat *cluster* dilakukan secara random.
- c. Setiap data ditempatkan ke pusat *cluster* terdekat berdasarkan jarak antar objek. Pada tahap ini jarak dihitung dengan menentukan kemiripan atau ketidakmiripan data dengan Metode Jarak *Euclidean* (*Euclidean Distance*) dengan rumus. [13]

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Dimana :

$d(x, y) = \text{ukuran ketidakmiripan.}$

$x_i = (x_1, x_2, \dots, x_j)$ yaitu variabel data.

$y_i = (y_1, y_2, \dots, y_j)$ yaitu variabel pada titik pusat.

- d. Hitung pusat *cluster* yang baru dengan anggota yang baru dengan cara menghitung rata-rata objek pada *cluster*. Perhitungan ini bisa juga dengan menggunakan *median*.
- e. Hitung kembali jarak tiap objek dengan pusat *cluster* baru, hingga *cluster* tidak berubah, maka proses *clustering* selesai.[7]

2.1.1.2 Algoritma *Hierarchical*

Hierarchical adalah algoritma *clustering* dengan teknik membentuk pembagian bersarang (*nested partition*). Berbeda dengan K-Means yang hasil *clustering*-nya berbentuk *flat* atau rata, *hierarchical* memiliki satu *cluster* paling atas yang mencakup konsep seluruh *cluster* di bawahnya.[11] Untuk mendapatkan bentuk *hierarchical* ada 2 cara, yaitu :

- a) Agglomerative. Dimulai saat beberapa *flat clusters*, terjadi pada setiap langkah iterasi dengan menggabungkan 2 *clusters* yang mirip. Artinya, kita mendefinisikan arti “kedekatan” pada dua *clusters*.
- b) Divisive. Dimulai dari satu *cluster* (seluruh data), kemudian kita memecah belah *cluster*. Artinya, kita harus mendefinisikan *cluster* mana yang harus dipecah dan bagaimana cara memecahnya.[11]

Metode *hierarchical* memiliki hasil pengelompokan yang membentuk suatu tingkatan seperti struktur pohon, ini terjadi karena proses pengelompokan pada metode ini dilakukan secara bertingkat. Hasil dari *clustering* direpresentasikan sebagai dendogram, yang menunjukkan

bagaimana pengelompokkan terbentuk dan nilai koefisien jarak pada tiap langkah. Fungsi jarak yang dipakai adalah Metode Jarak *Euclidean* (*Euclidean Distance*) dengan rumus.[13]

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Dimana :

$d(x, y)$ = ukuran ketidakmiripan.

$x_i = (x_1, x_2, \dots, x_j)$ yaitu variabel data.

$y_i = (y_1, y_2, \dots, y_j)$ yaitu variabel pada titik pusat.

2.1.1.2.1 Hierarchical Agglomerative dengan Metode Ward

Pengelompokkan dengan metode Ward dilakukan dengan memperkecil total jumlah kuadrat dalam kelompok dibentuk sedemikian sehingga menghasilkan kelompok dengan jumlah kuadrat terkecil dan dikenal dengan *Error Sums of Squares* (*ESS*). Dua *cluster* yang memiliki peningkatan *ESS* paling minimum akan berkelompok. Jika cluster terbanyak c maka *ESS* merupakan penjumlahan dari ESS_c . Ketika semua *cluster* bergabung menjadi satu kelompok dari N item, maka nilai *ESS* dirumuskan dalam persamaan :

$$ESS = \sum_{j=1}^n (x_j - \bar{x})(x_j - \bar{x})$$

Dengan x_j matriks multivariat objek ke- j dan $\bar{x}$ adalah *mean* dari semua objek.

Berikut merupakan rumus ESS_c :

$$ESS = ESS_1 + ESS_2 + \dots + ESS_c$$

[12].

2.1.1.2 Algoritma DBSCAN

DBSCAN atau *Density Based Spatial Clustering of Applications with Noise* adalah algoritma *clustering* berbasis densitas yang mampu menangani *noise* dan *outlier* dengan efektif. DBSCAN ini mengidentifikasi *cluster* sebagai area dengan kepadatan tinggi yang dipisahkan oleh area dengan kepadatan rendah. DBSCAN tidak memerlukan penentuan jumlah *cluster* terlebih dahulu dan mampu mendeteksi *cluster* dengan bentuk yang beragam.[8] Jadi, DBSCAN sangat efektif dalam analisis spasial, seperti mendeteksi pola keramaian disuatu wilayah atau mengidentifikasi perilaku anomali.[9] Namun, DBSCAN juga punya kelemahan yaitu memiliki sensitivitas terhadap pemilihan parameter radius dan minimum points. [8]

DBSCAN bekerja dengan dua parameter utama yaitu ϵ (*epsilon*) jarak atau radius maksimum untuk menentukan kedekatan antar titik dan *MinPts* adalah jumlah minimum titik dalam radius ϵ agar suatu titik tidak dapat dianggap sebagai bagian inti *cluster* (*core point*). Berdasarkan kedua parameter tersebut, titik data dapat dikategorikan menjadi 3 jenis yaitu :

1. *Core point* : Memiliki jumlah tetangga $\geq MinPts$ radius ϵ .
2. *Border point* : Berada dalam radius ϵ dari *core point*, tetapi jumlah

tetangganya $< MinPts$.

3. *Noise (Outlier)* : Tidak termasuk *core point* maupun *border point*.

Langkah-langkah DBSCAN adalah sebagai berikut :

- a. Inisialisasi status semua data (objek) dalam dataset sebagai belum dikunjungi (*unvisited*).
- b. Pilih secara acak sebuah objek p yang belum pernah dikunjungi, lalu tandai p sebagai objek yang sudah dikunjungi (*visited*).
- c. Jika lingkungan di sekitar p memiliki objek sekurang-kurangnya sebanyak $MinPts$, maka buat cluster baru C dan tambahkan p ke dalam C . [10] Penentuan objek yang masuk ke dalam lingkungan tersebut menggunakan batasan radius jarak persamaan :

$$N_{\epsilon}(x) = \{y \in D \mid d(x, y) \leq \epsilon\}$$

Dimana :

$N_{\epsilon}(x)$: himpunan titik dalam radius ϵ dari titik x

D : keseluruhan himpunan data.

$d(x, y)$: jarak antara titik x dan y .

ϵ : parameter jarak maksimum.

Syarat core point:

$$|N_{\epsilon}(x)| \geq MinPts$$

Artinya, jika jumlah tetangga sebuah titik dalam radius ϵ minimal sebesar $MinPts$, maka titik tersebut menjadi pusat *cluster*. [9]

- d. Jadikan himpunan objek berada di dalam lingkungan p tersebut sebagai N . Untuk setiap titik p' yang ada di dalam N , lakukan hal berikut ini :
- e. Jika pada langkah 3 objek p tidak memiliki setidaknya $MinPts$ objek di sekitarnya, maka tandai objek p tersebut sebagai *noise*.
- f. Ulangi langkah 2 sampai 5 hingga tidak ada lagi objek yang berstatus belum dikunjungi, sehingga didapatkan kumpulan cluster berbasis kepadatan beserta anggotanya masing-masing. [10]

2.1.2 Algoritma Time Series

Data *time series* merupakan data yang diurutkan berdasarkan waktu kejadian mulai dari hitungan detik hingga tahun[6]. Pendekatan analitik pada data *time series* bertujuan untuk mengekstraksi dan mempelajari pola historis yang tersembunyi—seperti tren dan musiman—guna memprediksi atau meramalkan (*forecasting*) nilai di masa depan. Algoritma-algoritma time series menggunakan metode pembelajaran *unsupervised learning* dimana data masa lalu menjadi variabel independen (X) untuk memprediksi nilai di masa depan yang menjadi target (y).

2.1.2.1 Algoritma LSTM (Long Short Term Memory)

Algoritma Long Short-Term Memory (LSTM) merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk mengatasi keterbatasan RNN, terutama masalah *vanishing gradient* dan kemampuan menyimpan informasi jangka panjang. LSTM memiliki dua komponen utama, yaitu *cell state* sebagai memori jangka panjang (*long-term memory*) dan *hidden state* sebagai memori jangka pendek (*short-term memory*), yang dikendalikan oleh tiga gerbang (*gate*), yaitu *forget gate*,

input gate, dan *output gate*.

Proses pada LSTM dimulai dengan menghitung nilai *forget gate*, yang berfungsi menentukan seberapa besar informasi pada *cell state* sebelumnya yang akan dipertahankan. Nilai ini diperoleh dari hasil fungsi sigmoid yang menghasilkan nilai antara 0 hingga 1, kemudian dikalikan dengan nilai *cell state* sebelumnya.

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

Keterangan :

- x_t = input pada waktu ke-t
- h_{t-1} = hidden state sebelumnya
- W_f = bobot forget gate
- b_f = bias forget gate
- σ = fungsi sigmoid

Selanjutnya, LSTM menghitung nilai *input gate* untuk menentukan seberapa banyak informasi baru yang akan disimpan ke dalam *cell state*. Pada tahap ini, dibentuk terlebih dahulu *candidate cell state* atau *potential long-term memory* dengan menggabungkan input saat ini dan *hidden state* sebelumnya menggunakan bobot (*weight*) dan bias, kemudian diproses menggunakan fungsi aktivasi tanh. Nilai kandidat tersebut dikalikan dengan keluaran *input gate* untuk memperbarui *cell state*.

a. Menghitung persentase informasi baru yang akan diingat

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

Keterangan :

- σ = fungsi sigmoid
- W_i = Bobot input
- h_{t-1} = hidden state sebelumnya
- x_t = input pada waktu ke-t
- b_i = bias input

b. Menghitung candidate cell state (potential long-term memory)

$$\tilde{C}_t = \tanh(W_c [h_{t-1}, x_t] + b_c)$$

Keterangan:

- $\tanh$ = fungsi aktivasi tanh
- W_c = Weight Cell State
- h_{t-1} = hidden state sebelumnya
- x_t = input pada waktu ke-t
- b_c = bias cell state

c. Memperbarui cell state

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

Ket:

- f_t = forget gate
- C_{t-1} = cell state sebelumnya
- i_t = input gate

- $\tilde{C}_t$ = cell state baru
- $\odot$ = perkalian elemen demi elemen (*element-wise multiplication*)

Setelah nilai *cell state* diperbarui, LSTM menghitung *output gate* yang bertugas menentukan informasi apa yang akan diteruskan sebagai *hidden state* baru. Nilai *output gate* diperoleh dari hasil fungsi sigmoid yang menerima kombinasi input saat ini dan *hidden state* sebelumnya. Sementara itu, *cell state* yang telah diperbarui diproses menggunakan fungsi tanh untuk menghasilkan *potential short-term memory*. Hasil tanh tersebut kemudian dikalikan dengan keluaran *output gate* sehingga diperoleh *hidden state* atau *short-term memory* yang baru.

a. Menghitung nilai output gate

$$O_t = \sigma(W_o [h_t - 1, x_t] + b_o)$$

b. Menghitung potential short-term memory

$$\tanh(C_t)$$

Nilai hidden state diperoleh dengan mengalikan output gate dengan hasil transformasi tanh dari cell state.

$$h_t = O_t \odot \tanh(C_t)$$

Dengan:

- h_t = hidden state di waktu t

- O_t = output gate
- C_t = cell state yang telah diperbarui

Secara umum, perhitungan nilai pada *forget gate*, *input gate*, dan *output gate* dilakukan dengan mengalikan input saat ini dan *hidden state* sebelumnya dengan bobot masing-masing, kemudian menambahkan bias. Hasilnya diproses menggunakan fungsi sigmoid untuk menghasilkan nilai persentase yang menentukan informasi mana yang dipertahankan, ditambahkan, atau dikeluarkan oleh LSTM.

2.2 Dataset yang digunakan

2.2.1 Teori Data dan Tipe Data

Menurut Wiroromi dkk. (2024) data dapat dibagi menjadi beberapa jenis berdasarkan strukturnya, diantaranya adalah Data Terstruktur, Data Semi-terstruktur dan Data Tidak terstruktur dan *Data Streaming*. Data Terstruktur adalah data yang telah tertata dalam format yang jelas, baku dan terdefinisi sebelumnya, seperti database relasional atau file berbentuk CSV. Data Semi-terstruktur memiliki struktur yang lebih longgar tetapi tetap mengandung beberapa struktur atau metadata yang terkait. Data Tidak Terstruktur adalah data yang tidak memiliki struktur formal atau definisi yang jelas, sering berbentuk teks bebas, gambar, audio dan video. *Data streaming* adalah data terus menerus mengalir dalam waktu nyata (*realtime*). Seperti data sensor, data transaksi keuangan atau data media sosial yang terus diperbarui.

Selain strukturnya, atribut di dalam dataset juga memiliki tipe yang berbeda-beda. Secara umum, tipe data dalam *data mining* dapat dikelompokkan menjadi :

- a. Data Numerik : Tipe data yang terdiri dari angka atau nilai kuantitatif yang

dapat dihitung. [6] Contohnya adalah nilai koordinat, kedalaman dan magnitudo.

- b. Data Kategorikal : Tipe data yang terdiri dari kategori atau label diskrit yang mewakili karakteristik tertentu. [6] Contohnya adalah kode jaringan institusi atau status verifikasi data.
- c. Data Teks : Data berupa urutan karakter atau kata-kata. Contohnya dokumen teks, ulasan produk dan tweet.
- d. Data Spasial atau Geografis : Tipe data ini berhubungan dengan lokasi atau koordinat geografis. Contohnya data peta, koordinat GPS atau informasi lokasi.
- e. Data Gambar : Data gambar terdiri dari representasi visual dari objek atau scene, berupa pixel-pixel data atau fitur-fitur yang diekstraksi dari gambar.
- f. Data Multivariat : Data yang terdiri dari beberapa variabel atau atribut yang terkait satu sama lain dan merupakan kombinasi dari tipe data numerik, kategorikal atau lainnya. [6]

Dataset ini tidak hanya memiliki satu jenis nilai saja, tetapi menggabungkan dari beberapa tipe data yang saling terkait. Kombinasinya meliputi :

- a. Data Numerik: Atribut berupa angka kuantitatif yang bisa dihitung nilainya, seperti kekuatan gempa (mag), kedalaman (depth), margin eror (rms, horizontalError, depthError), kesenjangan sudut (gap), dan jumlah stasiun (nst, magNst).
- b. Data Kategorikal: Atribut berupa label diskrit untuk pengelompokan, seperti metode perhitungan (magType), kode jaringan (net), status verifikasi (status), serta institusi sumber data (locationSource dan magSource).
- c. Data Teks: Berupa untaian karakter bebas yang menjelaskan deskripsi nama tempat pada atribut place.

2.2.2 Deskripsi Dataset Proyek

Seperti yang sudah dijelaskan di Batasan bagian Dataset & Wilayah, data akan disaring terlebih dahulu menggunakan batas resmi berdasarkan Zona Ekonomi Eksklusif (ZEE) Indonesia yang bersumber dari MarineRegions dan juga data batas daratan Indonesia dari pustaka python OSMNX. Dataset yang sudah disaring akan dikategorikan ke dalam Data Terstruktur berformat CSV dengan total volume data sebanyak 57.743 baris. Untuk memberikan pemahaman mengenai karakteristik isi data sebelum memasuki *pre-processing*, berikut adalah penjelasan dari ke-22 kolom atribut yang tersedia di dalam dataset secara berurutan :

- a. time: Waktu dan tanggal presisi terjadinya gempa bumi dengan format ISO 8601 (contoh: 2004-12-31T17:48:05.740Z).
- b. latitude: Titik koordinat spasial lintang lokasi episentrum gempa.
- c. longitude: Titik koordinat spasial bujur lokasi episentrum gempa.
- d. depth: Kedalaman pusat gempa diukur dari permukaan bumi (dalam satuan kilometer).
- e. mag: Skala kekuatan gempa atau Magnitudo (rentang di datamu dari 2.7 hingga 9.1).
- f. magType: Metode atau skala perhitungan magnitudo yang dipakai oleh stasiun pencatat (contoh: mb, mwc, mww).
- g. nst: Jumlah total stasiun seismik yang digunakan untuk mendeteksi dan menentukan lokasi gempa tersebut.
- h. gap: Kesenjangan sudut (azimuth) terbesar antara stasiun pencatat terdekat.
- i. dmin: Jarak horizontal dari pusat gempa ke stasiun seismik pendeteksi terdekat.
- j. rms: Root-mean-square atau nilai tingkat margin eror waktu tempuh deteksi gelombang seismik.

- k. net: Kode inisial dari jaringan atau institusi penyedia data gempa (misalnya: us untuk USGS).
- l. id: Kode unik pencatatan untuk setiap kejadian gempa.
- m. updated: Waktu dan tanggal kapan data rekaman gempa ini terakhir kali diperbarui atau direvisi di sistem.
- n. place: Deskripsi lokasi kejadian gempa dalam bentuk teks (contoh: "92 km SSW of Banda Aceh, Indonesia").
- o. type: Jenis kejadian seismik.
- p. horizontalError: Nilai ketidakpastian atau margin eror saat sensor membaca titik koordinat lokasi kejadian.
- q. depthError: Nilai ketidakpastian atau margin eror saat sensor membaca kedalaman pusat gempa.
- r. magError: Nilai ketidakpastian atau margin eror saat sensor menghitung kekuatan magnitudo gempa.
- s. magNst: Jumlah stasiun seismik yang datanya digunakan secara khusus untuk menghitung besaran magnitudo.
- t. status: Status peninjauan data (contoh: reviewed yang berarti datanya sudah diverifikasi oleh ahli seismologi secara manual).
- u. locationSource: Institusi atau jaringan yang melakukan verifikasi akhir terhadap lokasi gempa.
- v. magSource: Institusi atau jaringan yang melakukan verifikasi akhir terhadap kekuatan magnitudo gempa.

2.3 Preprocessing Data

Preprocessing data adalah serangkaian langkah yang dilakukan untuk mengubah data mentah menjadi format yang siap untuk dianalisis atau dimodelkan. Tujuan dari *preprocessing* adalah untuk meningkatkan kualitas data, mengurangi *noise* dan memastikan format sudah sesuai. *Preprocessing* sangat penting dilakukan, jika tidak akan mempengaruhi hasil analisis dan keputusan bisnis yang akan diambil.[6] Proses umum dari *preprocessing data* adalah :

- a. Pembersihan data (*Data Cleaning*) : Membersihkan data dengan mengidentifikasi dan memperbaiki atau menghapus data yang tidak akurat, tidak lengkap atau tidak konsisten.
- b. Integrasi Data (*Data Integration*) : Menggabungkan data dari berbagai sumber menjadi satu *dataset* yang koheren.
- c. Transformasi data (*Data Transformation*) : Mengubah data menjadi format yang sesuai dengan persyaratan analisis atau model.
- d. Pembagian data (*Data Splitting*) : Membagi data menjadi set pelatihan (*training*) dan set pengujian (*testing*) untuk mengevaluasi model.[6]

2.4 Evaluasi Model

Dalam model clustering ada beberapa hal yang dapat mengukur kualitas hasil clustering yaitu sebagai berikut :

- a. *Sum of Squared Errors* (SSE) merupakan jumlah kuadrat jarak antara setiap titik data dalam *cluster* dengan menunjukkan kelompok yang lebih padat dan data yang lebih seragam dalam kelompoknya. Namun, SSE cenderung menurun saat jumlah kelompok meningkat, sehingga SSE sendiri tidak memberikan ukuran yang objektif untuk kualitas *clustering*.
- b. *Silhouette Score* digunakan untuk mengukur seberapa baik setiap titik data dalam *cluster* cocok dengan *clusternya* sendiri bahkan dibandingkan dengan *cluster* lain.

Silhouette Score berkisar dari -1 hingga 1, dimana nilai yang akan lebih tinggi menunjukkan *clustering* yang lebih baik. Nilai *Silhouette Score* yang positif menunjukkan bahwa titik data cocok dengan *clusternya*, sedangkan nilai yang negatif menunjukkan bahwa titik data mungkin cocok dengan *cluster* lain. Nilai yang mendekati nol menunjukkan bahwa titik data berada dekat dengan batas antara dua *cluster*.

- c. *Davies Bouldin Index* (DBI) digunakan untuk mengukur seberapa baik sebuah *cluster* terpisah satu dengan yang lain. Dengan cara menghitung rata-rata ukuran rasio komponen kohesi dan separasi antara dua *cluster*. Nilai *Davies Bouldin Index* rendah menunjukkan *cluster* terpisah satu sama lain dengan baik, sedangkan nilai tinggi menunjukkan adanya tumpang tindih antar *cluster*. [6]

2.5 CRISP-DM

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) merupakan suatu kerangka kerja standar dalam proses data mining yang dikembangkan pada tahun 1999 oleh beberapa perusahaan besar untuk menyediakan pendekatan yang terstruktur dan sistematis dalam pengolahan data. Framework ini dirancang agar dapat digunakan secara umum tanpa bergantung pada jenis software maupun jenis data tertentu. CRISP-DM terdiri dari enam tahapan utama, yaitu Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment. Keenam tahapan tersebut saling terhubung dan digunakan sebagai pedoman dalam menjalankan proyek data mining agar proses analisis data dapat dilakukan secara lebih efektif, terarah, dan menghasilkan model yang bermanfaat.

2.5.1 Business Understanding

Business Understanding adalah Tahapan dimana mengetahui atau memahami secara pasti masalah apa yang ingin diselesaikan sebelum menyentuh datanya. Ini adalah fase perencanaan dan penetapan tujuan.

2.5.2 Data Understanding

Data Understanding merupakan tahap penting dalam proses data mining yang bertujuan untuk memahami, mengenali, dan mengevaluasi data sebelum digunakan pada tahap analisis maupun pemodelan. Pada tahap ini dilakukan identifikasi terhadap sumber data, struktur data, arti setiap atribut, serta kualitas data yang dimiliki. Proses ini penting karena data sering kali tersebar di berbagai tempat, memiliki format yang berbeda, atau mengandung informasi yang tidak lengkap dan tidak konsisten. Selain itu, tahap Data Understanding juga mencakup pemeriksaan terhadap akurasi, kelengkapan, dan reliabilitas data agar hasil analisis yang diperoleh dapat dipercaya. Dengan memahami karakteristik data secara menyeluruh, peneliti dapat menentukan metode preprocessing dan pemodelan yang paling sesuai sehingga proses data mining dapat menghasilkan informasi dan prediksi yang lebih optimal.

2.5.3 Data Preparation

Data Preparation merupakan tahap dalam proses data mining yang bertujuan untuk mempersiapkan data agar siap digunakan dalam proses analisis dan pemodelan. Pada tahap ini, data yang berasal dari berbagai sumber dan memiliki format yang berbeda akan diolah menjadi lebih terstruktur, konsisten, dan berkualitas. Data dapat berbentuk angka, teks, gambar, maupun informasi naratif sehingga diperlukan penyesuaian format agar data dapat diproses secara optimal oleh sistem analisis. Proses Data Preparation meliputi penggabungan beberapa dataset, pemilihan atribut yang relevan, pembersihan data dari missing value, duplikasi, noise, maupun outlier, serta transformasi format data agar memiliki konsistensi yang seragam. Tahap ini sangat penting karena kualitas data yang telah dipersiapkan akan sangat memengaruhi performa dan akurasi model data mining maupun machine learning yang digunakan. Dengan melakukan Data Preparation yang baik, proses analisis dapat menghasilkan informasi dan prediksi yang lebih akurat,

efektif, dan dapat dipercaya.

2.5.4 Modeling

Modeling merupakan tahap dalam proses data mining di mana data yang telah dipahami dan dipersiapkan mulai diolah menggunakan algoritma tertentu untuk menemukan pola, hubungan, maupun informasi tersembunyi pada data. Pada tahap ini dibangun sebuah model, yaitu representasi terkomputerisasi dari kondisi atau fenomena nyata berdasarkan data yang dimiliki. Model dalam data mining umumnya dibedakan menjadi dua jenis utama, yaitu model klasifikasi dan model prediksi. Model klasifikasi digunakan untuk mengelompokkan data ke dalam kategori tertentu berdasarkan pola yang ditemukan, sedangkan model prediksi digunakan untuk memperkirakan atau meramalkan nilai maupun kejadian di masa mendatang. Selain itu, beberapa model dapat memiliki fungsi klasifikasi dan prediksi secara bersamaan, seperti Decision Tree yang mampu menentukan atribut penting sekaligus memprediksi kemungkinan suatu data masuk ke kategori tertentu. Tahap Modeling menjadi bagian penting karena pada tahap inilah proses data mining mulai menghasilkan pengetahuan baru melalui penerapan algoritma machine learning maupun statistik terhadap data yang telah dipersiapkan sebelumnya.

2.5.5 Evaluation

Evaluation merupakan tahap dalam proses data mining yang bertujuan untuk menilai kualitas, performa, dan kegunaan model yang telah dibangun pada tahap modeling. Pada tahap ini dilakukan evaluasi untuk mengetahui apakah model mampu menemukan pola yang benar-benar relevan dan menghasilkan prediksi yang akurat. Proses evaluasi penting dilakukan karena tidak semua model mampu menghasilkan informasi yang bernilai, bahkan beberapa model dapat menghasilkan false positive atau kesimpulan yang keliru akibat pola yang sebenarnya tidak signifikan. Evaluasi dapat

dilakukan menggunakan berbagai teknik, baik secara matematis maupun logis, seperti cross-validation, pengujian akurasi model, maupun pengukuran error prediksi. Selain itu, tahap evaluation juga mempertimbangkan aspek manusia, yaitu pengetahuan dan pengalaman peneliti dalam menilai apakah hasil model masuk akal dan sesuai dengan kondisi nyata. Dengan demikian, tahap evaluation membantu menentukan apakah model layak digunakan, perlu diperbaiki, atau memerlukan pemilihan metode yang berbeda agar dapat menghasilkan analisis dan prediksi yang lebih optimal.

2.5.6 Deployment

Deployment merupakan tahap akhir dalam proses data mining yang bertujuan untuk menerapkan model yang telah dibuat dan dievaluasi agar dapat digunakan dalam kondisi nyata. Pada tahap ini, hasil analisis dan model yang dianggap telah memiliki performa baik mulai diintegrasikan ke dalam sistem atau proses operasional sehingga dapat memberikan manfaat bagi pengguna maupun organisasi. Aktivitas pada tahap deployment meliputi otomatisasi model, integrasi dengan sistem informasi yang sudah ada, penyampaian hasil kepada pengguna, serta pemantauan performa model secara berkelanjutan. Selain itu, tahap ini juga mencakup proses evaluasi lanjutan terhadap hasil implementasi untuk meningkatkan akurasi dan efektivitas model di masa mendatang. Namun, penerapan model sering kali menghadapi tantangan berupa keraguan atau ketidakpercayaan terhadap hasil prediksi yang dihasilkan oleh sistem komputer. Oleh karena itu, diperlukan komunikasi yang jelas mengenai fungsi, manfaat, dan cara kerja model agar pengguna dapat memahami serta memanfaatkan hasil data mining secara optimal. Dengan deployment yang baik, model data mining tidak hanya menjadi hasil penelitian semata, tetapi juga dapat digunakan sebagai alat pendukung pengambilan keputusan dalam situasi nyata.

2.5.7 Conclusion

[Penjelasan teori Conclusion...]

2.6 Penelitian Terdahulu (5 tahun terakhir) minimal 5

Jurnal	Fokus Penelitian	Metode Penelitian	Temuan Utama	Kelemahan yang ditemukan
Smart Seismic Intelligence Machine Learning for Spatial Clustering and Earthquake Magnitude Prediction in Indonesia	Segmentasi wilayah gempa tektonik dan prediksi besaran magnitudo di Indonesia berdasarkan letak geografis dan kedalaman.	<i>K-Means Clustering</i> dan <i>Random Forest Regression</i> .	- Berhasil mengidentifikasi 4 zona klaster gempa di Indonesia secara spasial ($k=4$) - Faktor spasial, khususnya bujur (<i>longitude</i>) dan kedalaman, memiliki kontribusi terbesar dalam memprediksi magnitudo gempa.	- Ukuran dataset sangat kecil (hanya 67 sampel), yang memicu terjadinya <i>overfitting</i> ekstrim pada model prediksi . - Model tidak mempertimbangkan faktor temporal jangka panjang maupun fitur geologis seperti jenis sesar.
Deep Learning Approach in Seismology: Enhancing Earthquake	Peningkatan akurasi prakiraan kejadian gempa bumi	<i>Pra-pemrosesan (Magnitude Threshold, Depth Binning, K-Means</i>	Model yang diusulkan mengungguli metode	Model rentan gagal dalam meramalkan anomali atau

Forecasting using K-Means Clustering and LSTM Networks	di wilayah dengan tingkat keragaman spasial tinggi (Sulawesi).	<i>Clustering) dan model prediksi Long Short-Term Memory (LSTM) 4 lapis.</i>	konvensional (<i>baseline</i>) dengan nilai <i>Mean Square Error</i> (MSE) 0,379816 dan <i>Root Mean Square Error</i> (RMSE) 0,616292. • Teknik <i>clustering</i> dan pengelompokan kedalaman di fase awal terbukti efektif mereduksi <i>noise</i> dari data spasial yang beragam.	gempa langka (<i>rare event forecasting</i>) karena isu ketidakseimbangan kelas (<i>class imbalance</i>). • Kurangnya interpretabilitas model membuatnya sulit untuk memahami dinamika fisik dari kejadian seismik itu sendiri. • Masih berfokus pada optimasi lapisan (<i>hyperparameter</i>) dibandingkan mencoba arsitektur mendalam lain.
--	--	--	---	---

Analysis of earthquake hazards prediction with multivariate adaptive regression splines	Prediksi tingkat bahaya gempa (berdasarkan nilai percepatan tanah / PGA) untuk zonasi wilayah di Lombok.	<i>Multivariate Adaptive Regression Splines (MARS) dan CMARS (Non-parametrik).</i>	• Jarak episentrum adalah faktor paling dominan (100%) dalam menentukan tingkat kerusakan gempa, mengalahkan magnitudo (31,1%) . • Menghasilkan daftar 9 kecamatan di Lombok dengan tingkat bahaya tertinggi untuk panduan mitigasi.	• Model berfokus memprediksi <i>dampak bahaya</i> (PGA) setelah parameter gempa diketahui, bukan memprediksi waktu atau probabilitas terjadinya gempa di masa depan. • Belum memasukkan fitur spasial kondisi batuan dasar (<i>bedrock</i>) ke dalam dataset prediktor secara spesifik.
Application of Bisecting K-Means Method in Grouping Earthquake Data (Case Study Earthquakes in Indonesia 2023)	Pengelompokan data historis gempa bumi di Indonesia (tahun 2023) berdasarkan	<i>Bisecting K-Means Clustering dengan uji evaluasi Davies Bouldin Index (DBI).</i>	• Membentuk 3 kluster optimal (k=3) yang merepresentasikan gempa	• Analisis hanya sebatas pemetaan deskriptif historis, tidak

	kedalaman dan parameter spasial.		dalam, dangkal, dan menengah. • Gempa dangkal mendominasi frekuensi kejadian terbanyak di Indonesia, dengan titik paling aktif di area Semenanjung Minahasa (Sulawesi).	memiliki kapabilitas prediktif untuk prakiraan gempa di masa depan. • Hanya menggunakan satu metode dan data spesifik satu tahun, sehingga belum teruji untuk pola jangka panjang.
Earthquake trend prediction using long short-term memory RNN	Memprediksi tren urutan kejadian gempa bumi masa depan (lokasi, kedalaman, magnitudo, waktu) berdasarkan <i>time-series</i> data global	<i>Recurrent Neural Network (RNN) dengan arsitektur Long Short-Term Memory (LSTM) dan Feed Forward Neural Network (FFNN).</i>	• Model LSTM jauh lebih unggul logis dibandingkan dalam memetakan spasial gempa di depan. • Skor metrik evaluasi (R^2) model LSTM lebih baik daripada dasar FFNN.	• Skor akurasi model LSTM secara keseluruhan masih bernilai negatif, membuktikan bahwa prediksi angka absolut untuk fenomena gempa belum bisa dicapai hanya


				mengandalkan deret waktu historis semata. • Model murni matematis dan mengabaikan parameter prekursor fisik/geologis dari bumi itu sendiri.
--	--	--	--	--

Table 2.1 Penelitian terdahulu

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian



Gambar 3.1 Alur Penelitian

3.1.1 Ekstraksi dan Seleksi Data

Data gempa bumi diunduh dari website USGS dengan memfilter data berdasarkan tahun dan batas wilayah berbentuk persegi di wilayah Indonesia. Detail

filter yang digunakan adalah sebagai berikut.

1. Magnitude ≥ 2.5
2. Date and time : 2000-01-02 18:43:31.940000+00:00 sampai 2026-05-22 01:05:08.540000+00:00
3. Latitude : -12.261, 6.439
4. Longitude : 94.131, 141.328

Setelah itu data akan diseleksi sesuai dengan batas wilayah Indonesia sesuai peraturan ZEE. Pembersihan ini menggunakan 2 data tambahan dari MarineRegions dan library Python OSMNX.

3.1.2 Exploratory Data Analyses (EDA)

EDA yang dilakukan antara lain adalah eksplorasi temporal (frekuensi bulanan, heatmap frekuensi tahun vs bulan), analisis deskriptif data (cek missing values, value counts), visualisasi distribusi per kolom numerik, matriks korelasi, serta visualisasi spasial longitude, latitude, dan depth dari seluruh kejadian.

3.1.3 Preprocessing Data

Sebelum data memasuki pemodelan clustering, dilakukan preprocessing untuk memberikan, menambahkan informasi, dan encoding. Pembersihan kolom yang memiliki missing value tinggi. pemecahan kolom datetime kejadian menjadi tahun, bulan, tanggal, jam, menit, detik, dan milidetik. Encoding kolom place yang berisi informasi tempat regional kejadian menjadi frekuensi tempat tersebut disebutkan.

3.1.4 Clustering

Diuji 6 skenario kombinasi fitur, masing-masing dievaluasi dengan Elbow Method untuk menentukan k optimal, lalu dibandingkan secara visual (scatter 2D & 3D). Setelah itu dipilih fitur inti (longitude, latitude, depth) untuk menjalankan tiga

algoritma: K-Means ($k=4$), Hierarchical/Agglomerative (Ward linkage + KNN connectivity graph, agar hemat memori), dan DBSCAN. Ketiganya dibandingkan secara visual (2D/3D) dan dievaluasi dengan Silhouette Score; metode dengan skor terbaik dipilih sebagai final_label.

3.1.5 Evaluasi Hasil Clustering dan Penentuan Interval Waktu Prediksi

Hasil cluster divalidasi dari sisi waktu: frekuensi bulanan per cluster, distribusi magnitudo/kedalaman per cluster, heatmap aktivitas per bulan, dan proporsi cluster per tahun. Dilanjutkan analisis frekuensi mingguan (boxplot, histogram) untuk membandingkan interval waktu mana yang terbaik untuk diprediksi frekuensinya.

3.1.6 Pemodelan LSTM Tiap Cluster

Dilakukan feature selection dengan Random Forest untuk menentukan fitur paling berpengaruh terhadap frekuensi mingguan. Data diagregasi mingguan (frekuensi, magnitudo maksimum, kedalaman rata-rata), di-scale, lalu dibentuk menjadi sequence (sliding window time steps) untuk input LSTM. Model LSTM dilatih untuk memprediksi 3 target sekaligus: frekuensi, magnitudo maksimum, dan kedalaman rata-rata minggu berikutnya. Terdapat juga grid search untuk mencoba berbagai kombinasi hyperparameter (time_steps, activation, capacity, dropout, batch size).

3.1.7 Finishing: evaluasi & interpretasi hasil

Tahap akhir berupa perbandingan hasil prediksi vs aktual (frekuensi, magnitudo, kedalaman) pada data test, yang nantinya bisa diringkaskan dengan metrik seperti RMSE/MAE dan diinterpretasikan untuk menarik kesimpulan penelitian — misalnya cluster mana yang paling aktif, seberapa baik model memprediksi pola aktivitas gempa, dan implikasinya terhadap pemahaman pola seismik di Indonesia.

3.2 Business Understanding

Business Understanding adalah Tahapan dimana mengetahui atau memahami secara pasti masalah apa yang ingin diselesaikan sebelum menyentuh datanya. Ini adalah fase perencanaan dan penetapan tujuan.

Tujuan daripada proyek ini yakni untuk menghasilkan informasi prediksi jumlah frekuensi kejadian gempa berdasarkan data pola aktivitas gempa per karakter zona seismik di Indonesia.

Keberhasilan proyek ini diukur dari beberapa hal :

1. Algoritma clustering mampu melakukan pembagian zona seismik yang memiliki kualitas pembagian yang baik berdasarkan silhouette score
2. Model lstm mampu memprediksi frekuensi kejadian gempa per karakter zona seismik dalam rentang waktu mingguan dengan tingkat error yang rendah berdasarkan metrik evaluasi MSE dan RMSE

3.3 Data Understanding

3.3.1 Sumber Pengumpulan Data

Data yang digunakan dalam proyek ini bersumber dari katalog dataset milik *United States Geological Survey* (USGS). Pengumpulan data difokuskan pada aktivitas seismik di wilayah Zona Ekonomi Eksklusif (ZEE) Indonesia dengan rentang waktu observasi selama kurang lebih 26 tahun, terhitung mulai dari 2 Januari 2000 hingga 22 Mei 2026. Dari proses ekstraksi data awal ini, berhasil dikumpulkan himpunan data mentah (*raw data*) sebanyak 52.656 *records* kejadian gempa.

3.3.2 Deskripsi Dataset

Fitur-fitur yang termuat pada dataset ini, yakni :

Fitur	Tipe	Rentang / Nilai
Latitude, longitude	Numerik	Koordinat episentrum
depth	Numerik	0 - 675,5 km
mag	Numerik	2,7 - 9,1
magtype	Kategorik	11 tipe
Gap, rms, magnst	Numerik	Parameter kualitas pengukuran
place	Teks	Lokasi kejadian

Tabel 3.1 Deskripsi Dataset

3.3.3 Exploratory Data Analysis (EDA)

Pada tahapan EDA, terdapat beberapa insight yang dihasilkan terkait data aktivitas seismik, yakni :

- Frekuensi kejadian gempa wilayah ZEE Indonesia mengalami rata-rata 166,1 kejadian gempa per bulannya dan mencapai total 1.031 kejadian gempa dalam satu bulan pada puncaknya
- Didapati jumlah *missing value* (NULL) sangat masif di beberapa fitur, seperti horizontal error dengan rasio NULL mencapai 53,93%, diikuti dengan mag_error mencapai 50,13%, dan dmin mencapai 49,85%. Selain itu terdapat juga fitur dengan rasio NULL yang minim, gap dan magnst dengan rasio NULL 7,62% dan 7,07%
- Didapati pula dari total 52.656 data terdapat beberapa data noise dan duplikasi dengan menyisakan 52.623 data yang dianggap valid dan bersih

3.4 Data Preparation

Data Preparation merupakan tahap dalam proses data mining yang bertujuan untuk mempersiapkan data agar siap digunakan dalam proses analisis dan pemodelan. Pada tahap ini, data yang berasal dari berbagai sumber dan memiliki format yang berbeda akan diolah menjadi lebih terstruktur, konsisten, dan berkualitas. Data dapat berbentuk angka, teks, gambar, maupun informasi naratif sehingga diperlukan penyesuaian format agar data dapat diproses secara optimal oleh sistem analisis.

Pada proyek ini, *data preparation* dilakukan dalam 8 langkah yang berbeda, yaitu (1) pemfilteran spasial wilayah Indonesia, (2) penanganan *missing values*, (3) konversi tipe data temporal, (4) ekstraksi komponen waktu, (5) penghapusan atribut yang tidak relevan, (6) pembersihan atribut lokasi, (7) *encoding* atribut kategorik dan (8) pemeriksaan korelasi antar fitur.

3.4.1 Pemfilteran Spasial Wilayah Indonesia

Data mentah yang didapatkan dari USGS merupakan data yang mencakup seluruh dunia, sehingga data perlu dibatasi pada wilayah Indonesia. Pemfilteran dilakukan dengan menggunakan dua sumber geospasial :

- a. Zona Ekonomi Eksklusif (ZEE) Indonesia diambil dari berkas *ezz_v12.gpkg* yang berasal dari *MarineRegions* dengan filter `TERRITORY! == 'Indonesia'`.
- b. Batas daratan Indonesia diambil melalui pustaka *OSMNX* dengan fungsi `geocode_to_gdf("Indonesia")`.

Keduanya lalu diubah menjadi sistem koordinat EPSG:4326. Sebelumnya ZEE diproyeksikan ke EPSG:3857 (sistem metrik) untuk dilakukan *buffering* sebesar 20.000 meter atau 20 km, ini berguna untuk mengakomodasi titik gempa yang berada tepat di garis batas, lalu dikembalikan ke EPSG:4326. Selanjutnya kedua poligon disatukan menggunakan operasi `union_all()` agar menghasilkan poligon tunggal wilayah Indonesia baik daratan maupun perairan.

Data gempa kemudian dikonversi menjadi GeoDataFrame dengan geometri titik berdasarkan kolom longitude dan latitude, setelah itu dilakukan *spatial join* dengan predikat within terhadap poligon Indonesia. Hasil akhir dari *data preparation* ini berupa variabel data_gempa yang hanya berisi kejadian gempa yang terjadi di wilayah teritorial Indonesia.

3.4.2 Penanganan Missing Values

Setelah data melalui pemfilteran selanjutnya dilakukan pemeriksaan presentasi nilai kosong pada setiap atribut. Berikut distribusi *missing values* yang ditemukan tersaji dalam Tabel 3.1.

Atribut	Persentase Kosong
horizontalError	53,93%
magError	50,13%
dmin	49,85%
nst	35,45%
depthError	29,45%
gap	7,62%
magNst	7,07%
rms	0,06%

Tabel 3.2 Distribusi *missing values*

Strategi penanganan akan ditentukan berdasarkan persentase kekosongannya. Jika atribut memiliki kekosongan lebih dari 25%, maka atribut akan dihapus karena kekosongan tersebut beresiko menghasilkan bias yang besar. Berdasarkan Tabel 3.1 atribut yang dihapus adalah horizontalError, magError, dmin, nst dan depthError. Kemudian, untuk atribut dengan kekosongan kurang dari 25% seperti atribut gap (7,62%) dan magNst (7,07%) akan diisi dengan nilai median masing-masing kolom.

Karena distribusinya cenderung skewed sehingga median lebih robust terhadap *outlier* dibanding mean. Sedangkan untuk atribut rms(0,06%) dengan kekosongan yang tersisa akan dihapus menggunakan dropna() karena jumlahnya sangat kecil dan tidak signifikan terhadap data.

3.4.3 Konversi Tipe Data Temporal

Atribut seperti time dan updated yang awalnya bertipe *object/string* diubah menjadi tipe datetime64[ns, UTC] menggunakan pd.to_datetime(). Langkah ini digunakan agar *resampling* mingguan atau bahkan bulanan dan ekstraksi komponen waktu dapat berjalan dengan benar pada tahap selanjutnya.

3.4.4 Ekstraksi Komponen Waktu (Feature Engineering Temporal)

Untuk memperkaya representasi temporal, kolom time untuk diuraikan menjadi 7 atribut baru :

Atribut	Ekstaksi dengan
tahun	dt.year
bulan	dt.month
tanggal	dt.day
jam	dt.hour
menit	dt.minute
detik	dt.second
milidetik	dt.microsecond // 1000

Table 3.3 Representasi Temporal

Atribut hasil ekstraksi ini akan digunakan untuk analisis pola musiman/harian gempa pada tahap clustering dan pembentukan timestamp lengkap pada tahap prediksi LSTM.

3.4.5 Penghapusan Atribut Tidak Relevan

Setelah komponen waktu diekstrak, atribut yang tidak memberikan kontribusi pada analisis tidak akan dipakai, atribut-atribut tersebut adalah :

id	Atribut tidak memiliki nilai prediktif
status	Hanya menunjukkan status verifikasi (<i>reviewed/automatic</i>)
time & updated	Saat proses ekstraksi atribut sudah digantikan
geometry	Setelah melalui proses filtering, atribut ini sudah tidak diperlukan

Table 3.4 Atribut yang tidak memberikan kontribusi

3.4.6 Pembersihan Atribut Lokasi (Place)

Kolom place memiliki format yang sangat bervariasi, antara lain :

- Format standar : “X km <arah> of <Wilayah>, <Negara>”, contoh ; “123 km SSW of Sinabung, Indonesia”.
- Format pesisir : “off the coast of <Wilayah>”, contoh ; “off the coast of Sumatra”.
- Format nama khusus zona laut : contoh ; “Banda Sea”, “Molucca Sea”, “Java Sea”.

Agar semuanya seragam, dibuat fungsi `clean_place()` yang akan menerapkan aturan dibawah ini secara berurutan dengan ekspresi reguler (re) :

- Jika teks termasuk daftar zona laut khusus (Banda Sea, Molucca Sea, Celebes Sea, Flores Sea, Arafura Sea, Java Sea, Timor Sea, Savu Sea, South China Sea), teks dipertahankan apa adanya.
- Jika mengandung pola "off the coast of", diekstrak nama wilayah setelah frasa tersebut.

- c. Jika mengandung kata penghubung " of ", diambil bagian setelahnya dan dipotong sebelum tanda koma.
- d. Sebagai fallback, diambil bagian sebelum tanda koma pertama.

Hasil pembersihan kemudian disimpan dalam kolom baru `clean_location`.

3.4.7 Encoding Atribut Kategorik

Karena algoritma *machine learning* hanya menerima input numerik, maka dilakukan konversi melalui dua teknik *encoding*, yaitu sebagai berikut :

- a. *One-Hot Encoding*, diterapkan pada atribut dengan kardinalitas rendah yang tidak memiliki urutan (nominal), yaitu `magType`, `net`, `status`, `type`, `magSource`, dan `locationSource`. Setiap nilai unik pada atribut tersebut diubah menjadi kolom biner tersendiri (bernilai 0 atau 1). Proses ini dilakukan menggunakan fungsi `pd.get_dummies()` dan menghasilkan penambahan kolom secara signifikan (atribut `magType` saja menghasilkan 11 kolom baru), sehingga jumlah atribut bertambah menjadi 39 kolom.
- b. *Frequency Encoding*, diterapkan pada `clean_location` karena kardinalitas tinggi (banyak nilai unik) sehingga one-hot akan menghasilkan terlalu banyak kolom. Setiap nilai lokasi diganti dengan jumlah kemunculannya pada dataset, menghasilkan atribut numerik `location_freq_enc`. Setelah encoding, kolom asli `clean_location` dan `place` dihapus.

3.4.8 Pemeriksaan Korelasi Antar Fitur

Sebagai langkah verifikasi sebelum pemodelan, dilakukan analisis korelasi Pearson terhadap 12 fitur inti yaitu : `latitude`, `longitude`, `depth`, `mag`, `gap`, `rms`, `magNst`, `tahun`, `bulan`, `tanggal`, `jam`, dan `location_freq_enc`. Hasil korelasi divisualisasikan dalam bentuk heatmap dengan skala -1 dengan +1 bertujuan untuk :

- a. Mengidentifikasi multikolinearitas antar fitur prediktor.

- b. Memilih kombinasi fitur yang paling informatif untuk skenario *clustering* pada tahap berikutnya.

Hasil tahap *data preparation* ini menghasilkan variabel akhir data_ancoded yang sudah bersij, bertipe numerik dan siap digunakan pada tahap modeling.

3.5 Modeling

Tahap *modeling* merupakan tahap ke-4 di dalam kerangka CRISP-DM, *modeling* bertujuan menerapkan algoritma *machine learning* terhadap data yang telah disiapkan [10]. Dalam proyek ini, kami menggunakan pendekatan *two-stage hybrid modeling* dengan menggabungkan tahap *clustering* untuk mengelompokkan kejadian gempa berdasarkan karakteristik spasialnya, dilanjutkan dengan *forecasting* menggunakan LSTM pada *cluster* terpadat. Pendekatan dengan dua tahap ini efektif untuk memprediksi gempa karena prediksi *time-series* dilakukan pada subpopulasi yang lebih homigen, sehingga pada pola waktunya lebih konsisten.

3.5.1 Standardisasi Fitur

Sebelum dataset dimasukkan ke algoritma berbasis jarak seperti K-Means, Agglomerative, DBSCAN ataupun LSTM seluruh fitur numerik akan distandardisasi menggunakan StandarScaler dari *scikit-learn*. Teknik ini mentransformasikan setiap fitur agar memiliki rata-rata 0 dan standar deviasi 1 dengan rumus :

$$z = \frac{x - \mu}{\sigma}$$

Dengan x adalah nilai asli, μ adalah rata-rata fitur dan σ standar deviasinya. Standardisasi diperlukan karena rentang nilai antar atribut sangat berbeda seperti longitude dalam derajat, depth dalam kilometer dan mag dalam skala Richter, sehingga jika tidak disetarakan skalanya fitur dengan rentang besar akan mendominasi perhitungan pada jarak Euclidean.

3.5.2 Pemodelan Clustering

Clustering adalah proses pengelompokan data atau objek ke dalam kelompok-kelompok yang serupa berdasarkan kesamaan karakteristik tertentu. Karakteristik setiap cluster adalah kemiripan data yang tinggi di dalam satu cluster-nya dan ketidakmiripan data yang tinggi pada cluster lainnya.[6]

3.5.2.1 Eksperimen Skenario Fitur dengan K-Means

Untuk menemukan kombinasi dan jumlah *cluster* terbaik, maka kami menguji dengan menggunakan skenario kombinasi fitur yaitu sebagai berikut :

Skenario	Fitur yang Digunakan
Skenario 1	longitude, latitude, depth, mag
Skenario 2	longitude, latitude, depth
Skenario 3	Seluruh kolom data_encoded
Skenario 4	longitude, latitude, depth, location_freq_enc
Skenario 5	longitude, latitude, depth, location_freq_enc, mag
Skenario 6	12 fitur inti (lat, lon, depth, mag, gap, rms, magNst, tahun, bulan, tanggal, jam, location_freq_enc)

Tabel 3.5 Skenario Uji K-Means

Setiap skenario diuji menggunakan Elbow Method dengan rentang $k=2$ sampai $k=10$. Algoritma K-Means dijalankan dengan parameter `random_state=42` dan `n_init=10` untuk memastikan stabilitas inisialisasi *centroid*. Nilai WCSS (*Within Cluster Sum of Squares*) dihitung untuk setiap k , kemudian diplot untuk menemukan titik “siku” yang paling bagus, yaitu titik dimana penurunan WCSS mulai melandai. Titik siku tersebut diinterpretasikan sebagai jumlah *cluster* optimal karena penambahan *cluster* setelahnya hanya

memberikan penerununan WCSS yang marginal.

3.5.2.2 Validasi Silhouette pada Sampel

Karena perhitungan *Silhouette Score* pada seluruh data (puluhan ribu baris) sangat mahal komputasinya, validasi dilakukan pada sampel acak 5.000 baris dengan `random_state=42`. Untuk setiap skenario, diuji tiga nilai k , yaitu $k_{\text{terbaik}} - 1$, k_{terbaik} dan $k_{\text{terbaik}} + 1$. Matrik yang dihitung adalah :

- WCSS (Inertia) : semakin kecil nilainya, maka menunjukkan *cluster* semakin kompak
- Silhouette Score : dengan rentang -1 sampai +1, semakin mendekati +1 menunjukkan *cluster* yang semakin terpisah dengan baik.

3.5.2.3 Pemodelan Final dengan Tiga Algoritma

Berdasarkan hasil eksperimen, fitur yang dipilih untuk pemodelan final adalah [longitude, latitude, depth] yaitu pada skenario 2. Data distandardisasi terlebih dahulu menjadi `df_scaled`, kemudian diterapkan 3 algoritma *clustering* untuk pembandingan :

- K-Means

Parameter yang digunakan :

<code>n_clusters = 4</code>
<code>random_state = 42</code>
<code>n_init = 10</code>

Tabel 3.6 Parameter K-Means

- Agglomerative Hierarchical Clustering

Parameter yang digunakan :

<code>n_clusters = 3</code>
<code>linkage = 'ward'</code>
<code>connectivity = kneighbors_graph(df_scaled, n_neighbors=10, include_self=False)</code>

Table 3.7 Parameter AHC

Untuk keperluan visualisasi struktur hierarki, dilakukan perhitungan dendrogram menggunakan `scipy.cluster.hierarchy.linkage` dengan metode 'ward' pada sampel acak 5.000 baris, ditampilkan dengan `truncate_mode='lastp'` dan `p=12` untuk menampilkan 12 cabang terakhir.

c. DBSCAN

Parameter yang digunakan :

<code>eps = 0.18</code> (radius ketetanggaan pada data terstandarisasi)
<code>min_samples = 20</code> (jumlah titik minimum untuk membentuk core point)
<code>algorithm = 'ball_tree'</code>

Tabel 3.8 Parameter DBSCAN

Nilai `eps` sengaja dipilih relatif kecil agar zona-zona padat pada jalur subduksi tetap dapat terpecah menjadi cluster yang berbeda, bukan menggumpal menjadi satu.

3.5.2.4 Pemilihan Model Terbaik

Pemilihan algoritma sebagai model terbaik dilakukan berdasarkan nilai *Silhouette Score*. Untuk DBSCAN, titik *noise* (label-1) diesklusi terlebih dahulu sebelum perhitungan *Silhouette* agar tidak bias. Algoritma dengan

Silhouette Score tertinggi dipilih sebagai model akhir dan label *cluster*-nya disimpan sebagai kolom *final_label* pada DataFrame *data_clustered*.

3.5.3 Pemodelan Forecasting dengan LSTM

3.5.3.1 Pemilihan Cluster Target

Dari hasil *clustering*, dipilih Cluster 2 sebagai target peramalan karena merupakan *cluster* paling padat (frekuensi kejadian terbanyak), sehingga deret waktunya paling lengkap dan paling layak untuk pemodelan LSTM.

3.5.3.2 Feature Selection dengan Random Forest

Untuk menentukan fitur yang paling berpengaruh terhadap frekuensi gempa mingguan, digunakan Random Forest Regressor sebagai *feature selector* berdasarkan atribut *feature_importances_*. Konfigurasi :

n_estimators = 100
random_state = 42
n_jobs = -1

Tabel 3.9 Konfigurasi Feature Selection

Target Random Forest adalah frekuensi mingguan (hasil `resample('W').size()`). Sepuluh fitur dengan *importance* tertinggi dipilih sebagai *input* tambahan model LSTM.

3.5.3.3 Agregasi Mingguan Multivariate

Data gempa pada *Cluster 2* diagregasi ke level mingguan menggunakan `resample('W')` dengan aturan agregasi :

frekuensi	size() (jumlah kejadian per minggu)
-----------	-------------------------------------

mag	max() (magnitudo maksimum mingguan)
depth	mean() (kedalaman rata-rata mingguan)
Fitur lain	mean()

Tabel 3.10 Aturan Agregasi

Kalender mingguan kemudian di-reindex penuh dari minggu pertama hingga terakhir, dengan minggu kosong diisi nilai 0 untuk frekuensi dan forward-fill (ffill) untuk fitur lain. Tiga kolom target (frekuensi, mag, depth) diposisikan paling depan untuk kemudahan slicing.

3.5.3.4 Scaling Terpisah untuk Fitur dan Target

Standardisasi dilakukan dua kali secara terpisah :

scaler_features	StandardScaler untuk seluruh kolom (digunakan untuk input X).
scaler_target	StandardScaler khusus untuk tiga kolom target (digunakan untuk inverse transform hasil prediksi).

Tabel 3.11 Standardisasi

3.5.3.5 Pembentukan Sliding Window Dataset

Data sekuensial diubah menjadi format *supervised learning* dengan fungsi `create_dataset()` menggunakan sliding window :

TIME_STEPS = 4, menggunakan empat minggu sebelumnya sebagai input.
Untuk setiap indeks i : X_i = data minggu i sampai $i + 3$ (semua fitur), y_i = target minggu $i + 4$ (frekuensi, mag, depth)

Tabel 3.12 *Sliding window*

Pemisahan data dilakukan dengan 80:20 tanpa shuffle, yaitu 80% data training dan 20% data testing.

3.5.3.6 Arsitektur Model LSTM Multivariate Multi-output

Model LSTM menggunakan tensorflow.keras dengan arsitektur sebagai berikut :

Layer	Konfigurasi
LSTM-1	64 unit, aktivasi tanh, return_sequences=True
Dropout-1	rate = 0.2
LSTM-2	32 unit, aktivasi tanh, return_sequences=False
Dropout-2	rate = 0.2
Dense-1	16 unit, aktivasi ReLU
Dense-Output	3 unit (linear) dengan output frekuensi, mag, depth.

Tabel 3.13 Arsitektur tensorflow.keras

3.5.3.7 Grid Search Hyperparameter Tuning

Untuk menemukan kombinasi *hyperparameter* terbaik, dilakukan *grid search* eksaustif dengan :

Hyperparameter	Nilai yang Diuji
time_steps	4, 8
activation	tanh, hybrid (tanh • selu)
capacity	small (64→32), large (128→64)

Hyperparameter	Nilai yang Diuji
dropout_rate	0.1, 0.2
batch_size_replica	16, 32

Tabel 3.14 Ruang pencarian *grid search*

Total kombinasi yang diuji adalah $2 \times 2 \times 2 \times 2 \times 2 = 32$ konfigurasi model. Setiap model dilatih maksimal 50 epoch dengan EarlyStopping (monitor='val_loss', patience=5, restore_best_weights=True) untuk mencegah overfitting dan menghemat waktu komputasi. Setiap konfigurasi dievaluasi dengan tiga RMSE komponen (frekuensi magnitudo, kedalaman) serta skor rata-rata ketiganya :

$$Skor\ Rata - rata = \frac{RMSE_{frekuensi} + RMSE_{mag} + RMSE_{depthi}}{3}$$

Pencarian skor rata-rata ini dilakukan setelah nilai RMSE masing-masing komponen dinormalisasi atau dihitung dalam keadaan data masih scaled (sebelum di-inverse transform). Model dengan skor rata-rata terendah dipilih sebagai konfigurasi final.

3.6 Evaluation

Tahap evaluasi bertujuan untuk mengukur performa, stabilitas, dan keandalan model yang telah dibangun sebelum model diinterpretasikan atau diterapkan (deploy). Pada penelitian ini, proses pengujian stabilitas performa model dilakukan secara terpisah untuk tahap clustering dan forecasting, dengan rincian sebagai berikut:

3.6.1 Evaluasi Model Clustering

Pengujian kualitas pembagian klaster zona seismik menggunakan dua metode evaluasi internal:

3.6.1.1 Elbow Method

Elbow Method digunakan pada algoritma K-Means untuk mencari nilai k

(jumlah kluster) yang paling optimal. Pengujian dilakukan dengan melakukan iterasi parameter $k=2$ hingga $k=10$ dengan menghitung nilai metrik Within-Cluster Sum of Squares (WCSS). Titik "siku" (elbow) di mana penurunan nilai WCSS mulai melandai secara marginal ditetapkan sebagai jumlah kluster terbaik.

3.6.1.2 Silhouette Score

Silhouette Score: Digunakan untuk membandingkan performa struktur kluster antara tiga algoritma (K-Means, Agglomerative Hierarchical, dan DBSCAN). Mengingat besarnya volume data yang digunakan, perhitungan Silhouette Score diterapkan pada sampel acak sebesar 5.000 hingga 10.000 baris data (dengan menetapkan nilai `random_state=42` untuk menjaga konsistensi hasil pengujian). Skor ini mengevaluasi seberapa mirip suatu objek data dengan klasternya sendiri dibandingkan dengan kluster tetangga lainnya (memiliki rentang nilai -1 hingga $+1$). Model dengan skor tertinggi yang mendekati $+1$ akan dipilih sebagai arsitektur final untuk penentuan wilayah zonasi. Khusus untuk algoritma DBSCAN, titik data yang dilabeli sebagai pencilan/noise (label -1) dieksklusi terlebih dahulu sebelum perhitungan Silhouette Score dilakukan agar evaluasi berfokus murni pada kepadatan kluster yang terbentuk.

3.6.2 Evaluasi Model Forecasting (LSTM)

Untuk memastikan keandalan prediksi deret waktu (time-series), pengujian stabilitas model LSTM menggunakan metode pemisahan data (data splitting) secara kronologis berurutan sesuai urutan waktu (tanpa pengacakan atau shuffle). Data dibagi menjadi dua bagian, di mana 80% observasi awal bertindak sebagai data training dan 20% observasi terakhir sebagai data testing. Evaluasi stabilitas performa model dilakukan melalui tiga mekanisme:

3.6.2.1 Metrik Pengukuran Error

Performa prediksi kuantitatif dievaluasi menggunakan metrik Root Mean Square Error (RMSE) dan Mean Absolute Error (MAE). Evaluasi ini diterapkan pada ketiga output target model sekaligus secara simultan, yaitu prediksi frekuensi gempa mingguan, magnitudo maksimum mingguan, dan rata-rata kedalaman mingguan. Keselarasan kedua metrik ini digunakan sebagai tolok ukur kesesuaian target keberhasilan teknis model sains data yang dicanangkan.

3.6.2.2 Pencegahan Overfitting (Early Stopping)

Proses pelatihan model dijadwalkan berlangsung hingga 50 epoch. Namun, untuk mencegah terjadinya overfitting dan menjaga stabilitas performa pada data pengujian, mekanisme Early Stopping diterapkan untuk memantau nilai validation loss. Jika selama 5 epoch berturut-turut ($\text{patience}=5$) tidak terjadi penurunan validation loss yang signifikan, proses pelatihan akan dihentikan secara otomatis dan bobot model terbaik akan dikembalikan ($\text{restore_best_weights}=\text{True}$).

Optimasi Hyperparameter (Grid Search): Skenario Grid Search secara eksaustif dijalankan pada arsitektur LSTM dengan menguji 32 kombinasi parameter (mencakup variasi Time Steps, fungsi aktivasi, Capacity/Neurons, tingkat Dropout, dan Batch Size). Mengingat ketiga variabel target memiliki skala nilai asli yang berbeda jauh (satuan untuk frekuensi, skala Richter untuk magnitudo, dan ratusan kilometer untuk kedalaman), pemilihan kombinasi parameter terbaik didasarkan pada nilai rata-rata skor RMSE terendah lintas 3 target dalam keadaan data ternormalisasi (scaled RMSE). Hal ini dilakukan guna menghindari bias dominasi nilai error dari variabel dengan skala angka yang besar (seperti kedalaman) terhadap variabel berskala kecil. Setelah konfigurasi terbaik ditemukan, nilai error barulah ditransformasikan kembali ke skala asli (inverse transform) untuk kebutuhan visualisasi dan pembahasan.

3.7 Deployment

[Tuliskan rencana atau dokumentasi teknis pendeployan sistem di sini...]

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini bersumber dari katalog gempa bumi resmi *United States Geological Survey* (USGS). Dataset mentah (raw data) awal hasil unduhan memiliki total volume sebanyak 57.743 baris kejadian gempa bumi yang tercatat secara historis dalam rentang waktu dari tanggal 2 Januari 2000 hingga 22 Mei 2026. Untuk membatasi ruang lingkup analisis agar berfokus pada wilayah Indonesia, dilakukan proses pemfilteran spasial (*spatial filtering*) menggunakan metode *spatial join* (*gpd.sjoin*) berbasis batas wilayah laut Zona Ekonomi Eksklusif (ZEE) dan batas daratan teritorial Indonesia. Setelah proses penyaringan geografis tersebut, diperoleh dataset final terfilter dengan total volume sebanyak 52.656 baris observasi.

Pada tahap pra-pemrosesan (*preprocessing*), dataset final ini dieksplorasi dan dibersihkan secara intensif untuk meningkatkan kualitas serta validitas pemodelan berikutnya. Langkah-langkah pembersihan data yang dilakukan adalah sebagai berikut:

Penanganan Data Hilang (*Missing Value Handling*): Atribut-atribut numerik pendukung yang memiliki tingkat *missing value* sangat tinggi di atas 25% (seperti *horizontalError*, *magError*, *dmin*, *nst*, dan *depthError*) dihapus sepenuhnya dari dataset. Langkah eliminasi fitur ini diambil guna mencegah munculnya bias komputasi dan menghindari penurunan performa model akibat imputasi data yang terlalu masif.

Ekstraksi Fitur Temporal: Atribut waktu (*time*) yang semula bertipe *string/object* dikonversi menjadi format *datetime*, kemudian diekstraksi menjadi komponen waktu yang lebih granular, meliputi variabel tahun, bulan, tanggal, jam, menit, detik, hingga milidetik. Ekstraksi ini krusial untuk menangkap pola musiman (*seasonal patterns*) maupun tren harian dari aktivitas seismik.

Transformasi Fitur Spasial dan Kategorikal: Fitur tekstual informasi lokasi (*place*) dibersihkan menjadi zona spasial standar dan ditransformasikan menjadi representasi numerik menggunakan metode *Frequency Encoding*. Sementara itu, untuk fitur kategorikal lainnya yang berpusat pada atribut sumber data (*locationSource*, *magSource*) dan jenis gelombang perhitungan (*magType*), ditransformasikan menggunakan metode *One-Hot Encoding*.

Melalui serangkaian tahapan rekayasa fitur tersebut, dataset yang telah berformat terstruktur, bersih, dan terstandarisasi ini siap menjadi masukan (*input training*) yang kokoh untuk diintegrasikan ke dalam pemodelan *clustering* (K-Means, Agglomerative, DBSCAN) dan pemodelan *forecasting* (LSTM).

4.2 Hasil Preprocessing Data

Preprocessing data digunakan untuk memastikan data gempa bumi yang dipakai dalam pelatihan adalah data yang bersih, terintegrasi, tertransformasi dengan baik, dan siap digunakan untuk pemodelan. Data awal dari USGS, mentahnya memiliki 57.742 baris catatan gempa di Indonesia.

4.2.1 Pembersihan data (*Data Cleaning*)

Pembersihan dilakukan dengan berfokus pada kondisi data yang memiliki *missing value* yang banyak. Hal lain yang diperbaiki pada proses ini adalah pembersihan data dari rekaman-rekaman di luar wilayah Indonesia menggunakan batas Zona Ekonomi Eksklusif (ZEE) Indonesia milik MarineRegions dan batas daratan dengan data dari *library* OSMNX.

Aspek / Parameter	Sebelum Preprocessing	Sesudah Preprocessing
Jumlah Baris (<i>Rows</i>)	57.742 baris	52.623 baris hasil dair penghapusan naii <i>null</i> dan data di luar wilayah Indonesia
Jumlah kolom (<i>Columns</i>)	23 kolom bawaan	18 kolom tanpa kolom yang memliki banyak nilai <i>null</i>
Kolom dengan <i>missing values</i> tinggi	1. horizontalError : 53,93% 2. magError : 50,13% 3. dmin : 49,85% 4. Nst : 35,45% 5. depthError : 29,45%	Kolom-kolom tersebut dihapus sepenuhnya dari dataset karena persentase kekosongan data melebihi batas toleransi.
Kolom dengan <i>missing values</i> rendah	1. gap : 7,62% 2. magNst : 7,07% 3. Rms : 0,06%	Kolom gap & magNst diisi dengan menggunakan nilai Median. Baris kosong pada kolom rms dibersihkan dengan metode dropna().

Tabel 4.1 *Data Cleaning*

4.2.2 Pemfilteran Data (Data Filtration)

Untuk membersihkan data di luar daerah Indonesia, dilakukan filtrasi data menggunakan data tambahan yaitu data spasial poligon bats laut Zona Ekonomi Eksklusif (ZEE) serta data daratan Indonesia dari OSMNX guna membatasi ruang lingkup wilayah analisis hanya pada wilayah Indonesia saja.

Aspek / Parameter	Sebelum Preprocessing	Sesudah Preprocessing
Batasan Wilayah	Masih berupa garis kaku berbentuk kotak yang di atur pada saat pengambilan data dari USGS.	Sesuai dengan batas wilayah Indonesia baik daratan maupun lautannya.
Cakupan Koordinat Wilayah	Masih bercampur dengan koordinat wilayah dari negara lain di sekitar Indonesia.	Hanya pada batas wilayah Indonesia sesuai dengan ZEE dan daerah daratannya.
Jumlah Baris Data	57.743 baris data mentah.	52.656 baris data (terfilter hanya yang berada di dalam zona Indonesia).

Tabel 4.2 *Data Filtration*

4.2.3 Transformasi Data (Data Transformation)

Transformasi data dilakukan agar format yang awalnya berupa text atau string, dapat menjadi integer secara keseluruhan baik dengan *encoding* maupun metode lainnya.

Aspek / Parameter	Sebelum Preprocessing	Sesudah Preprocessing
Tipe Data Waktu (time & updated)	Bertipe <i>string</i> teks dengan standar ISO	Menjadi objek temporal bertima <i>datetime</i>
Ekstraksi Fitur Temporal	Hanya berupa satu kolom <i>datetime</i>	Dipecah menjadi 6 fitur penunjuk waktu baru : tahun, bulan, tanggal, jam, menit, dan detik
Fitur Teks Lokasi (place)	String teks tidak terstruktur (contoh : 100 km W of atau Banda Sea)	Dibersihkan melalui fungsi yang mengubahnya menjadi sebuah penamaan baku (clean_location). Lalu ditransformsikan ke numerik menggunakan metode Frequency Encoding. Hasilnya menjadi frekuensi penyebutah place dari tiap baris.
Fitur Kategorikal	Variabel kategorikal yang masih bertipe	Diubah menjadi <i>flag-flag</i> dari tiap kategori. Disebut juga metode <i>One-hot Encoding</i>

(magType, dsb)	<i>string</i>	
Skala Nilai Numerik	Memiliki rentang nilai antar fitur yang beragam, seperti pada <i>depth</i>	Seluruh fitur numerik ditransformasikan menggunakan <i>standard scaller</i>

Tabel 4.3 *Data Transformation*

4.2.4 Pembagian dan Pengelompokkan Data (*Data Splitting*)

Data dikelompokkan sesuai dengan rentang waktu yang telah disepakati, yaitu mingguan. Berikutnya data dibagi menjadi dua bagian berupa data latih dan data uji untuk kebutuhan model peramalan sekuensial LSTM

Aspek / Parameter	Sebelum Preprocessing	Sesudah Preprocessing
Struktur Dataset	Berbentuk data deret mentah per kejadian gempa individu.	Diagregasikan ke dalam bentuk data runtuk waktu mingguan menjadi sebanyak 1.377 urutan minggu.
Metode Pembagian Data	Dataset masih dalam satu kesatuan data tunggal secara utuh	Data dikelompokkan berdasarkan urutan waktu tanpa diacak
Rasio Pembagian	Tidak ada rasio perbandingan	Proporsi pembagian ditentukan sebesar 80% data latih dan 20% data uji.
Bentuk Input Sekuens	Berupa matriks 2 dimensi	Ditransformasikan menjadi struktur 3 dimensi dengan paramter <i>time_steps</i> = 4 (menggunakan pola histori 4 minggu ke belakang).
Dimensi Data Latih (<i>Train</i>)	Belum terbentuk	x_train : (1098,4,32) y_train : (1098,3)
Dimensi Data Uji (<i>Test</i>)	Belum terbentuk	x_test : (275,4,32) y_test : (275,3)

Tabel 4.4 *Data Splitting*

4.3 Hasil Modeling

Dalam projek ini, kami menggunakan pendekatan *two-stage hybrid modeling* dengan menggabungkan tahap *clustering* untuk mengelompokkan kejadian gempa berdasarkan karakteristik spasialnya, dilanjutkan dengan *forecasting* menggunakan LSTM pada *cluster*

terpadat.

4.3.1 Hasil *Clustering*

Evaluasi kualitas *cluster* diukur menggunakan silhouette Score dengan teknik *sampling* sebanyak 10.000 titik data (`random_state=42`). Hasil perbandingannya ada pada tabel 4.

Algoritma	Parameter	Silhouette Score
K-Means	$k = 4$	0,4553
Agglomerative Hierarchical	$k = 3$, <i>ward linkage</i>	0,4230
DBSCAN	$\text{eps} = 0,18$ (tanpa <i>noise</i>)	-0,2733

Tabel 4.5 Hasil *Clustering*

Berdasarkan Tabel 4.X, K-Means dengan $k = 4$ dipilih sebagai model klaster terbaik karena menghasilkan Silhouette Score tertinggi (0,4553), menandakan *cluster* dapat terpisah dengan baik. Agglomerative Hierarchical menempati posisi kedua (0,4230), sedangkan DBSCAN menghasilkan skor negatif (-0,2733), ini mengindikasikan banyaknya tumpang tindih antar *cluster* serta tingginya proporsi titik *noise*, sehingga tidak cocok untuk distribusi data gempa yang padat dan menyebar. Label *cluster* terbaik dari K-Means kemudian disimpan sebagai kolom `final_label` pada *dataframe* utama untuk dianalisis lebih lanjut.

4.3.1.1 Validasi Temporal *Cluster*

Untuk memastikan keempat *cluster* yang digunakan tidak hanya valid secara spasial tetapi juga bermakna secara temporal, maka dilakukan analisis konituitas aktivitas pada rentang 2 Januari 2000-22 Mei 2026. Hasilnya tersajikan dibawah ini :

Klaster	Minggu Sibuk	Minggu Tenang	Bulan Sibuk
Klaster 0	1.374 (99,78%)	3 (0,22%)	316 (100%)
Klaster 1	1.125 (81,70%)	252 (18,30%)	312 (98,73%)
Klaster 2	1.353 (98,26%)	24 (1,74%)	316 (100%)
Klaster 3	1.377 (100%)	0 (0,00%)	316 (100%)

Tabel 4.6 Hasil Temporal *Cluster*

Hasil validasi menunjukkan bahwa Klaster 3 merupakan zona paling aktif dan kontinu dengan aktivitas gempa tercatat di seluruh minggu maupun bulan (100%), diikuti Klaster 0 dan Klaster 2 yang juga sangat aktif (di atas 98% pada skala mingguan). Sebaliknya, Klaster 1 memiliki tingkat keheningan tertinggi dengan 252 minggu tenang (18,30%), mengindikasikan zona dengan aktivitas seismik yang lebih sporadis. Distribusi yang konsisten ini memperkuat bahwa pengelompokan K-Means menghasilkan klaster yang stabil sepanjang periode pengamatan.

4.3.2 Hasil Seleksi Fitur (Random Forest)

Sebelum pemodelan LSTM, dilakukan seleksi fitur menggunakan Random Forest untuk menentukan variabel paling berpengaruh terhadap frekuensi gempa mingguan. Sepuluh fitur dengan nilai importance tertinggi dipilih sebagai variabel input model.

Peringkat	Fitur	Importance
1	magSource_official	0,2145
2	magType_ms	0,1542
3	net_official	0,1376
4	magType_mwb	0,1309
5	magType_mwc	0,0607
6	gap	0,0459

Tabel 4.7 Fitur terpenting hasil Random Forest

Hasil pada Tabel 4.7 menunjukkan bahwa fitur yang berkaitan dengan sumber dan tipe pengukuran magnitudo (magSource_official, magType_ms, net_official, magType_mwb) mendominasi kontribusi terhadap prediksi frekuensi gempa, dengan total *importance* keempatnya mencapai lebih dari 63%. Fitur spasial seperti longitude dan latitude serta gap dan location_freq_enc turut memberikan kontribusi yang relevan, menegaskan bahwa karakteristik lokasi dan kualitas pencatatan sama-sama penting dalam membentuk pola temporal kegempaan.

4.3.3 Hasil Pemodelan LSTM

Data gempa diagregasi menjadi deret waktu mingguan menghasilkan struktur 1.377 baris $\times$ 32 kolom. Data kemudian dibentuk menjadi format supervised sequence (sliding window) dengan rincian: X_train berdimensi (1098, 4, 32) dan y_train berdimensi (1098, 3), di mana model memprediksi tiga target sekaligus (multi-output): frekuensi gempa, magnitudo maksimum, dan kedalaman rata-rata mingguan.

Layer	Output Shape	Jumlah Parameter
LSTM	(None, 4, 64)	24.832
Dropout	(None, 4, 64)	0
LSTM	(None, 32)	12.416
Dropout	(None, 32)	0
Dense	(None, 16)	528
Dense (output)	(None, 3)	51
Total		37.827 (147,76 KB)

Tabel 4.8 Hasil Pemodelan LSTM

Model dilatih selama 50 epoch. Nilai training loss menurun konsisten dari 1,0501 menjadi 0,4901, sementara validation loss bergerak dari 0,6247 dan berakhir di 0,7659 dengan validation MAE akhir 0,5735. Kenaikan validation loss pada epoch-epoch akhir mengindikasikan adanya gejala overfitting ringan, yang menjadi salah satu alasan dilakukannya grid search untuk menemukan konfigurasi yang lebih seimbang. Perbandingan antara hasil prediksi dan nilai aktualnya adalah sebagai berikut :

Aktual Frek.	Pred. Frek.	Aktual Max Mag	Pred. Max Mag	Aktual Mean Depth	Pred. Mean Depth
13,0	7,53	6,3	4,79	29,45	71,26
10,0	7,84	5,0	4,72	49,08	79,95
8,0	5,40	4,6	4,84	41,29	63,31
9,0	5,38	5,6	4,99	36,34	47,73
2,0	8,11	5,0	5,13	22,50	42,09
5,0	7,17	4,9	4,93	70,41	37,27

Tabel 4.9 Perbandingan Hasil Prediksi dan Aktual

Pola pada Tabel 4. Memperllihatkan bahwa model cenderung melakukan *smoothing* dimana ini memprediksi frekuensi tinggi terlalu rendah misalkan aktualnya adalah 13 lalu prediksinya 7,53 dan frekuensi rendah terlalu tinggi misalkan aktualnya 2 tetapi prediksinya 8,11. Prediksi magnitudo maksimum relatif paling stabil dan mendekati nilai aktual yaitu kisaran 4,7-5,1, sedangkan prediksi kedalaman rata-rata masih memiliki simpangan yang besar. Hal ini wajar mengingat sifat gempa yang sulit diprediksi secara presisi.

4.3.3.1 Hasil *Grid Search (Optimasi Hyperparameter)*

Untuk memperoleh konfigurasi optimal, dilakukan *grid search* terhadap 32 kombinasi *hyperparameter* yang mencakup *Time Steps* {4, 8}, *Activation* {tanh, hybrid}, *Capacity* {small, large}, *Dropout* {0,1; 0,2}, dan *Global Batch* {16, 32}. Lima konfigurasi terbaik (diurutkan berdasarkan Skor Rata-Rata RMSE terkecil).

Steps	Activation	Capacity	Dropout	Batch	RMSE Frek.	RMSE Max Mag	RMSE Mean Depth	Skor Rata-Rata
8	tanh	small	0,1	16	3,2504	0,4824	26,8105	10,1811
8	tanh	small	0,1	32	3,2722	0,4810	26,8079	10,1870
8	tanh	large	0,1	32	3,2826	0,4853	26,8145	10,1941
8	tanh	large	0,2	32	3,3718	0,4838	26,8368	10,2308
4	tanh	small	0,1	16	3,4511	0,4914	26,7547	10,2308

Tabel 4.10 Hasil *Grid Search*

Berdasarkan Tabel 4.10, konfigurasi terbaik adalah Time Steps = 8, fungsi aktivasi *tanh*, kapasitas *small*, *dropout* = 0,1, dan *global batch* = 16, dengan Skor Rata-Rata RMSE terendah sebesar 10,1811. Beberapa temuan penting dari proses optimasi ini:

- Fungsi aktivasi tanh secara konsisten mengungguli hybrid dan mendominasi seluruh peringkat atas.
- Time Steps = 8 lebih baik daripada 4 menunjukkan bahwa jendela historis yang lebih panjang membantu model menangkap pola temporal

kegempaan.

- c. Kapasitas small sudah memadai bertambahnya kapasitas model tidak memberikan peningkatan berarti, sekaligus mengurangi risiko overfitting.
- d. Dari ketiga target, magnitudo maksimum paling akurat diprediksi ($RMSE \approx 0,48$), sedangkan kedalaman rata-rata paling sulit ($RMSE \approx 26,81$) karena rentang nilainya yang sangat lebar (0–675 km).

4.4 Hasil Evaluasi Model

4.5 Pembahasan (Berisi Analisis Lengkap)

Penelitian ini mengusulkan sebuah pendekatan pemodelan hibrida dua tahap (*two-stage hybrid modeling*) yang mengintegrasikan algoritma *spatial-temporal clustering* dengan *deep learning forecasting*. Strategi ini bertujuan untuk memetakan zona seismik secara homogen sebelum melakukan proyeksi deret waktu, sehingga model dapat menangkap karakteristik sub-populasi data secara lebih spesifik dan terfokus.

4.5.1. Analisis Pemetaan Zona Seismik (Clustering)

Penerapan algoritma *K-Means* terbukti efektif dalam membagi luasnya wilayah geografis Indonesia ke dalam empat zona klaster spesifik berdasarkan kesamaan karakteristik kedalaman (*depth*), koordinat garis lintang (*latitude*), dan garis bujur (*longitude*). Hasil validasi temporal menunjukkan bahwa Klaster 2 dan Klaster 3 merupakan dua zona yang paling dominan dan aktif secara seismik di Indonesia.

Klaster 3, sebagai wilayah dengan kerentanan tertinggi, mencatat tingkat aktivitas kejadian yang konstan tanpa jeda, baik pada agregasi mingguan maupun bulanan (persentase aktivitas mencapai 100%). Sebaliknya, Klaster 1 diidentifikasi sebagai zona dengan intensitas kegempaan yang paling rendah (*silent cluster*), di mana terdapat rentang waktu sebanyak 252 minggu (18,30% dari total lini masa) yang bersih dari aktivitas gempa signifikan. Secara geologis, temuan ini sangat valid dan relevan dengan kondisi tektonik riil di lapangan. Wilayah-wilayah aktif pada klaster mayoritas merepresentasikan zona penunjaman (*subduction zone*) dan patahan aktif (*fault*) yang secara kontinu melepaskan akumulasi energi lempeng bumi, sementara wilayah pada klaster rendah berada pada bagian dalam lempeng (*intraplate*) yang memiliki struktur kerak bumi jauh lebih stabil.

4.5.2. Analisis Faktor Prediktor Frekuensi

Sebelum melangkah pada pemodelan sekuensial, tahapan seleksi fitur (*feature selection*) menggunakan algoritma *Random Forest Regressor* diterapkan untuk mengukur tingkat kepentingan variabel (*feature importance*). Temuan pada tahap ini memberikan wawasan yang menarik: selain parameter geospasial murni (koordinat dan kedalaman), atribut teknis yang berkaitan dengan sumber lembaga pencatat dan metode magnitudo gelombang (seperti *magSource_official*, *magType_ms*, dan *net_official*) memberikan kontribusi nilai *importance* akumulatif yang dominan, yaitu mencapai lebih dari 63%.

Fenomena ini menegaskan sebuah justifikasi penting dalam data sains kegempaan: untuk melakukan peramalan jangka pendek (skala mingguan), tingkat reliabilitas instrumen, sensitivitas sensor, serta keseragaman jaringan stasiun pencatat (*seismograph networks*) memegang peranan sebagai ujung tombak. Variasi data penunjang ini secara tidak langsung membantu model dalam memisahkan sinyal noise teoretis dari fluktuasi riil aktivitas pergerakan lempeng tektonik.

4.5.3. Analisis Peramalan Deret Waktu (LSTM)

Model prediksi berbasis *Long Short-Term Memory* (LSTM) dikembangkan secara khusus pada objek Klaster 2. Klaster ini dipilih karena memiliki densitas data deret waktu yang sangat padat dan kontinu, sehingga sangat ideal untuk menunjang proses pembelajaran sekuensial berbasis mekanisme *sliding window*.

Berdasarkan hasil pengujian pada data *testing*, model LSTM menunjukkan performa yang sangat stabil dan presisi tinggi dalam memproyeksikan metrik Magnitudo Maksimum mingguan, dengan rentang prediksi yang konsisten berada pada skala nilai aslinya, yaitu 4,7 hingga 5,1 skala Richter. Keberhasilan ini ditunjukkan oleh nilai error terkecil ($RMSE \approx 0,48$) pada pengujian makro, yang dipengaruhi oleh sempitnya skala sebaran data aktual magnitudo. Sebaliknya, prediksi untuk rata-rata kedalaman menghasilkan angka error nominal terbesar ($RMSE \approx 26,81$). Angka error yang terlihat membengkak ini bukan berarti performa model buruk, melainkan konsekuensi logis dari rentang nilai aktual kedalaman gempa bumi yang sangat lebar dan bervariasi melintasi skala ekstrem (antara 0 hingga 675 km).

Namun demikian, terdapat keterbatasan teoretis yang wajar saat model memprediksi variabel Frekuensi Kejadian Gempa. Model LSTM terpantau mengalami fenomena *smoothing* (penghalusan tren), di mana kurva prediksi cenderung berada pada nilai rata-rata (*mean*) dan gagal menyentuh titik-titik ekstrem nilai aktual. Sebagai contoh, ketika frekuensi aktual melonjak tajam hingga 13 kali kejadian dalam seminggu, model hanya memproyeksikan angka 7,53. Sebaliknya, saat kondisi di lapangan sedang tenang dengan hanya 2 kali kejadian seminggu, model menahan prediksinya di angka 8,11.

Fenomena *smoothing* ini lazim terjadi pada pemodelan *deep learning* untuk data alam yang bersifat *stochastic*. Aktivitas gempa bumi memiliki karakteristik pencaran *random walk* dengan tingkat *noise* kemunculan yang sangat tinggi. Pola historis murni akan mengalami kesulitan mendeteksi lonjakan anomali mendadak yang dipicu oleh pelepasan energi instan di bawah kerak bumi (*rare events*). Kendati memiliki keterbatasan dalam menangkap nilai puncak ekstrem, pendekatan hibrida ini secara keseluruhan terbukti sukses memberikan estimasi tren makro (arah pergerakan umum) yang logis dan empiris, apakah intensitas kemunculan gempa pada periode minggu berikutnya akan cenderung eskalatif (naik) atau de-eskalatif (mereda).

4.6 Implementasi / Deployment

[Lampirkan screenshot atau dokumentasi integrasi aplikasi yang sudah live di sini...]

BAB V

PENUTUP

5.1 Kesimpulan

[Tuliskan poin-poin kesimpulan tegas untuk menjawab rumusan masalah secara langsung di sini...]

5.2 Saran

[Tuliskan rekomendasi dan saran taktis untuk pengembangan riset ke depan di sini...]

DAFTAR PUSTAKA

- [1] Hadi, H. S., Rauf, R., Salim, A., & Firdaus, K. M. (2026). *Smart Seismic Intelligence Machine Learning for Spatial Clustering and Earthquake Magnitude Prediction in Indonesia*. *ZETROEM*, 8(1), 65-72.
<https://doi.org/10.36526/ztr.v8i1.7615>
- [2] Priyanto, D., Zarlis, M., mawengkang, H., & Efendi, S. (2022, June). *Analysis of earthquake hazards prediction with multivariate adaptive regression splines*. *International Journal of Electrical and Computer Engineering (IJECE)*, 12(3), 2885-2893.
<http://doi.org/10.11591/ijece.v12i3.pp2885-2893>
- [3] Wardhani, T. P. M., Tahir, Z., Warni, E., Bustamin, A., Imran Oemar, M. A. F., & Kayyum, M. A. (2025). *Deep Learning Approach in Seismology: Enhancing Earthquake Forecasting using K-Means Clustering and LSTM Networks*. *Journal Of Information And Communication Technology*, 24(1), 29-51.
<https://doi.org/10.32890/jict.2025.24.1.2>
- [4] K., V., Bhandarkar, T., Satish, N., Sridhar, S., Sivakumar, R., & Ghosh, S. (2019). *Earthquake trend prediction using long short-term memory RNN*. *International Journal of Electrical and Computer Engineering (IJECE)*, 9(2), 1304-1312.
<http://doi.org/10.11591/ijece.v9i2.pp1304-1312>
- [5] Rais, Z., Hafid, H., & Risqi, S. (2025). Application of Bisecting K-Means method in grouping earthquake data (Case study: Earthquakes in Indonesia 2023). *Inferensi*, 8(3), 263–270. <https://doi.org/10.12962/j27213862.v8i3.23335>
- [6] Wororomi, J. K., Reba, F., Mandowen, S. A., Sroyer, A. M., Manurung, H. E., Koibur, M. E., Pujiarini, E. H., Edy, M. R., Yuliana, H., Yusuf, M., & Dinata, R. M. (2024). *Data mining (Memahami pola di balik angka)*. Eureka Media Aksara.
- [7] Wahyudi, M., Masitha, Saragih, R., & Solikhun. (2020). *Data mining: Penerapan algoritma K-means clustering dan K-medoids clustering*. Yayasan Kita Menulis.

- [8] Rahayu, P. W., Sudipa, I. G. I., Suryani, Surachman, A., Ridwan, A., Darmawiguna, I. G. M., Sutoyo, M. N., Slamet, I., Harlina, S., & Maysanjaya, I. M. D. (2024). *Buku ajar data mining*. PT. Sonpedia Publishing Indonesia.
- [9] Munthe, I. R., Nasution, M., Hasibuan, M. I., Gunawan, I., Irawan, E., Hasibuan, M. N. S., Dalimunthe, B. A., Sepriani, Y., & Sitorus, S. P. (2025). *Metodologi penelitian: Perancangan sistem informasi dan data sains*. PT. Jasa Niaga Digital Indonesia.
- [10] Han, J., Pei, J., & Tong, H. (2023). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann.
- [11] Putra, J. W. G. (2020). *Pengenalan Konsep Pembelajaran Mesin dan Deep Learning* (Edisi 1.4). Self-published. <https://wiragotama.github.io/resources/ebook/intro-to-ml-secured.pdf>
- [12] Putri, N. A., & Soleh, Z. (2023). Pengelompokan daerah di Jawa Timur berbasis indikator kesejahteraan masyarakat dengan pendekatan analisis cluster hierarki. *Jurnal Statistika dan Aplikasinya*, 7(2), 143-156. <https://jurnal.unpad.ac.id/jsa/article/view/28221>
- [13] Ratnawati, D. E., Marjono, M., Widodo, N., & Anam, S. (2023). *Mendekode notasi SMILES: Ekstraksi fitur dan prediksi dengan machine learning*. UB Press.

